

Derin Öğrenme Yöntemi İle İnternet Sayfası Verisi Kazıma Sistemi

Web Page Information Extraction System by Using Deep Learning

Muhammet Pakyürek
Elektrik Elektronik Mühendisliği Bölümü
Düzce Üniversitesi
İstanbul, Türkiye
muhammetpakyurek@gmail.com

Mehmet Selman Sezgin
Veri Bilimi ve Analitiği Bölümü
ETSTUR
İstanbul, Türkiye
selman.sezgin@etstur.com

Selman Kulaç
Elektrik Elektronik Mühendisliği Bölümü
Düzce Üniversitesi
Düzce, Türkiye
selmankulac@duzce.edu.tr

Öz—Şirketlerde online satışı amaçlayan iş birimleri, pazar ile ilgili referans olabilecek her türlü veriye ihtiyaç duyarlar. Fiyat, içerik, anket vs. gibi çok sayıda farklı başlık altında toplanabilecek türlerdeki verileri, önceden belirlenmiş bir formatta toplamak için benzer ürünlerin satıldığı internet sayfaları kaynak olarak kullanılabilir. Veri toplama safhasında kullanılan yöntemleri, yöntem tekniği açısından 3 başlık altında toplayabiliriz: 1-Manuel 2-Yarı Manuel 3-Otomatik. Günümüzde internet sayfaları dinamik içerikli olduğundan ve internet sayfası tasarımlarında değişiklikler sıklıkla yapılabildiğinden, statik olarak kodlanmış veri toplayıcıları (1. ve 2. tip) uzun vadede sağlıklı veri toplayamamakta, devamlı olarak geliştirme ve bakım yükü getirmektedirler. Bu çalışmada veri toplama sürecinde internet sayfalarında yapılabilecek değişikliklerden etkilenmeyecek bir veri kazıma uygulaması geliştirildi (3.tip). Bu çalışma internet sayfalarındaki verileri, bir derin öğrenme modeli olan evrimsel yapay sinir ağıları kullanarak sayfa görüntülerinden elde etmeyi amaçlamaktadır.

Anahtar Sözcükler—Veri Kazıma, Görüntü İşleme, Derin Öğrenme, Evrimsel Yapay Sinir Ağları, Tarayıcı, Otel Fiyat

Abstract—In many companies, business units that aim to online sell, need every type of referential data about the market. In order to collect this data which can be group of price, content, survey etc. with a predefined format, websites which sell similar products can be used. The methods used in the data collection process are generally categorized by 3 main groups: 1-Manual 2-Half Manual 3-Auto. Statically coded data collectors (type 1 and type 2) are unable to collect healthy data in the long term and require continuous development and maintenance effort, as internet pages are dynamic and changes would happen frequently in their page designs. In this study, a data scraping application (type 3) which is not affected by structural changes in web pages was developed. This study aims to obtain data from images of web pages using Deep CNNs.

Keywords—Data Scraping, Image Processing, Deep Learning, Convolutional Neural Networks, Browsing, Hotel Price

I. GİRİŞ

İnternet kullanımının yaygınlaşmasından sonra internet ortamı her daim veri kaynağı olarak görülmüş ve bu ortamdan veriler elde edilmeye çalışılmıştır. Bir internet sayfasından veri elde ederken statik veri kazıyıcısı (HTML ağacındaki adresi kullanarak belirlenmiş bir alanın değerine ulaşma yöntemi) kullanmak akla gelen en pratik çözümdür. Ancak bu çözüm HTML ağacındaki en küçük değişikliklerde bile çalışamaz hale gelecek, amaçlanan veri kazıma işlemi sekteye uğrayacaktır. HTML’de kazınacak veriyi HTML ağacındaki yapıları sınıflandırarak belirleme [1], ağaçtaki hizalanmayı esas alan ve etiket-değer eşleştirme [2] [3] gibi yöntemler

incelediğinde, bu çalışmalarda ya eski usul statik HTML sayfaların göz önünde bulundurulduğu, ya da sayfanın bir bölümünü tamamen aldıktan sonra o bölüm üzerinde veri madenciliği yapıldığı görülmüştür. Bu yaklaşımlar, problemi sadece bir yönüyle ele alıp (sayfadaki tekrarlayan alanların tespiti, sayfada veri yoğunluğunun fazla olduğu kısımların tespiti vs.) akademik mahiyette sonuçlar üretmektedirler. Ancak anlatılan yöntemler günümüz internet sayfalarından (dinamik HTML üreten arayüz teknolojileri kullanan internet sayfaları. Teknoloji Örnekleri: Angular, React, Vue vs.) adaptif bir şekilde veri tarama ihtiyacını karşılamada yetersiz kalan yöntemlerdir. Bu sebeple bu bildiride internet sayfasının görüntüsü üzerinden istenilen verilerin (otel, acenta, fiyat bilgisi vb.) elde edilebileceği önerilmektedir. Bu doğrultuda internet sayfasının görüntüsünü alıp kaydeden, bu görüntüleri derin öğrenme modeli eğitmek için hazırlayan, sonrasında modeli eğtmek için nesnelerin olduğu koordinatları işaretleyen bir uygulama geliştirilmiştir. İşaretlenen verilerle, derin öğrenme modeli geliştirilmiştir ve bu modeli sınamak için, internet sitesinden taranmış ve model öğreniminde kullanılmamış görseller kullanılmıştır. Test verisi görsellerinde, resmin bozunum oranlarına göre farklı başarımlar elde edilmiştir. Model ile tespit edilen görsel odak alanları(otel, acenta, fiyat bilgisinin olduğu alanlar), optik karakter tanıma (OKT) [4] ile okunup bir veri tabanına aktarılmıştır.

II. AKADEMİK LİTERATÜR

Günümüzde makine öğrenmesi ile nesne bulma konusunda en iyi sonuçlar, temeli iki aşamalı yaklaşımlara dayanan algoritmalarla sağlanmaktadır [5]. Bu yaklaşım R-CNN (Regional CNN) [6] algoritması ile birlikte popülerleşmeye başlamıştır. İki aşamalı yaklaşımların birinci aşamasında potansiyel nesne adaylarının pozisyonları belirlenir. İkinci aşamada ise bu potansiyel nesne adaylarının pozisyonlarının gerçekten hedeflenen nesnelerden olup olmadığı belirlenir. İki aşamalı olan bu yaklaşım [7] ürettiği sonuçlar itibarıyla COCO ölçütlerinde [8] en yüksek doğruluk oranını yakalamıştır.

Tek aşamalı yaklaşımda ise bir seferde görseldeki tüm nesneler, pozisyonları ile birlikte yakalanabilmektedir. Bu konudaki en güncel ve başarılı çalışmalar YOLO (you only look once) [9] ve SSD (Single shot multibox detector) [10] yaklaşımlarıdır.

Bu çalışmada Keras Retinanet ¹ adlı kütüphane kullanılmıştır. Keras Retinanet, "Focal loss for dense object

¹<https://github.com/fizyr/keras-retinanet>

detection" [5] başlıklı çalışmadan esinlenerek oluşturulmuş açık kaynak kodlu bir kütüphanedir. Focal loss çalışmasının [5] en büyük katkısı, ağırlıkları güncellemede kullanılan hata fonksiyonunda, çapraz entropi yerine odak kaybı (focal loss) olarak isimlendirdikleri fonksiyonun kullanılmış olmasıdır. Böylece kötü performans gösterilen durumların (focal loss değerinin yüksek çıktığı durumlar) daha başarılı bir şekilde öğrenilmesi sağlanmıştır.

III. VERİ TANITIMI

A. Görsellerdeki Hedef Alanlar

Yaptığımız bu çalışmanın asıl hedefi rakip şirketlerin fiyat verilerine ulaşmaktır. Bu sebeple taranan görsellerde odaklanılan alanlar, fiyat bilgilerini içeren alanlardır. Fiyat alanları 4 adet farklı sınıf ile işaretlenmiştir. Bu sınıflar, *en düşük fiyat*, *alternatif fiyat 1*, *alternatif fiyat 2*, *alternatif fiyat 3* olarak isimlendirilmiştir. Görsellerde bu sınıflara ait olan alanlar üzerinden model eğitimi yapılmış, eğitilen modelin bu alanları yakalayabilmesi amaçlanmıştır. Bu alanlar model tarafından tespit edilebilir hale geldiğinde (önceden belirlenmiş test senaryolarında başarı limitlerini geçtiğinde) sadece odak alanların içinde kalan yazılar OCR kullanılarak çıkartılmış ve sınıf bilgisi ve otel bilgisi ile birlikte kaydedilmiştir.

Görsellerin elde edildiği web sayfalarının bağlantıları ile ilgili otellerin isimleri sistemimizde eşleştirilmiş oldukları için otel isimleri görsellerden taranacak alanlar arasına dahil edilmemiştir.



Şekil 1. Orjinal sayfa görseli

Şekil 1'de üzerinde çalışılan sayfanın örnek görseli yer almaktadır. Bu görselde en sağdaki bölümde en düşük fiyat bilgisi yer almakta, orta kısımdaki 3 farklı fiyat bilgisi ise alternatif fiyatlara (3 adet) adreslenmektedir.

B. Veri Nesne Kayıt Formatı

Veriler eğitilirken veya değerlendirilirken görsellerin ilgili alanlarında hangi nesnenin hangi koordinatlarda olduğunu gösteren açıklama dökümanı kullanılmaktadır. Açıklama dökümanının formatı aşağıda gösterilmiştir.

Dosya Dizini	Sol Üst (x, y)	Sağ Alt (x, y)	Sınıf
--------------	----------------	----------------	-------

Dosya dizini : Taranan görsellerin dosya sisteminde tutulduğu klasörün adresinin tutulduğu alandır. Aynı zamanda resmin otel bilgisi, giriş çıkış tarihleri gibi referans bilgileri de dosya adının içinde dolayısı ile bu alanda tutulmuştur.

Sol Üst (x, y) : Odaklanılan fiyat alanı dikdörtgeni içine alındığında ortaya çıkan dikdörtgenin sol üst köşesinin koordinat bilgisinin tutulduğu alandır.

Sağ Alt (x, y) : Odaklanılan fiyat alanı dikdörtgeni içine alındığında ortaya çıkan dikdörtgenin sağ alt köşesinin koordinat bilgisinin tutulduğu alandır. Dörtgenler bu 2 nokta ile belirlenebildiğinden diğer köşelerin bilgilerine ihtiyaç duyulmamıştır.

Sınıf : Dikdörtgen ile ifade edilen alanın hangi fiyat bilgisi sınıfına ait olduğunu belirten alandır.

TABLO I. VERİ I VE II KÜMELERİNDEKİ NESNE DAĞILIMLARI

Veri I		Veri II	
Sınıf	adet	Sınıf	adet
Alternatif Fiyat 1	22645	Alternatif Fiyat 1	22639
Alternatif Fiyat 2	20053	Alternatif Fiyat 2	20047
Alternatif Fiyat 3	14383	Alternatif Fiyat 3	14377
En Düşük Fiyat	28459	En Düşük Fiyat	28459

C. Veride Sınıflara Göre Dağılım

Model geliştirmek için kullanılmak üzere ilgili internet sayfasından daha önce belirlenmiş 400 otelin farklı tarihlerdeki fiyatlarını içeren görseller kaydedilmiştir. Kaydedilen bu veri 5728 adet görsel içermektedir. Modeli geliştirmek için var olan veriye ek olarak veri artırma ile üretilen veriler de kullanılmıştır. Veri artırma ile iki farklı veri seti üretilmiştir. Birinci veri seti, (Veri I), 2 adet yer değiştirme dönüşümü, 3 adet yaklaştırma ve uzaklaştırma dönüşümleri uygulanarak toplamda 28483 adete çıkarılmıştır.




Şekil 2. Veri II'de yerel bulanıklaştırma yapılmış veri örneği ve yapılan fiyat tespitleri


İkinci veri artırma işleminde ise 1 adet yer değiştirme, 1 adet uzaklaştırma yaklaştırma, 3 adet yerel bozulma ve bulanıklaştırma dönüşümleri kullanılarak yeni veriler Şekil 2'deki gibi oluşturularak veri sayısı 28465'e çıkarılmıştır. Veri I ve II'deki nesnelerin sınıflara göre dağılımları Tablo I'de gösterilmiştir. İki veri kümesindeki nesne dağılımlarının farklı olmasının nedeni, uygulanan dönüşüm sonucunda o sınıfa ait nesnenin resmin gerçek sınırlarının dışına tamamıyla çıkmış olmasıdır. Nesnelerden herhangi birinin sınırların dışında kaldığı durumlarda bu görseller için işaretleme yapılamamış, bu sebeple orijinal veri sayısının 5 katı sayıda artırılmış veri elde edilememiştir. Veri III'te ise elle yapılmış (gerçek senaryoda gerçekleşmesi beklenmeyen) büyük çaplı değişiklikler mevcuttur. Geliştirilen modelin bu tip değişiklik durumları için nasıl tahminler yaptığını gözlemlemek için oluşturulmuş 11 adet görsel bulunduran veri setidir.

IV. HTML AĞAÇ DEĞİŞİKLİĞİ PROBLEMİ

Bazı durumlarda tasarım değişikliği yapmak amacıyla, veri tarama uygulamalarına karşı savunma amaçlı ya da başka sebepler ile internet sayfası sahipleri internet sayfalarında HTML ağaç değişikliği yapabilmektedir.



Şekil 3. HTML Ağacı




Şekil 4. Değiştirilmiş HTML Ağacı

Bu değişiklik internet sayfasının görüntüsüne büyük / hiç bir etki etmemiş olsa dahi verinin elde edildiği düğümün ağaç içindeki adresi değişeceğinden statik olarak tanımlama ile veri tarama işlemi yapan uygulamalar ağacın bu yeni halinde veri taramakta başarısız olacaklardır. Söz konusu durum bu çalışmanın temel motivasyonunu oluşturmaktadır. Şekil 3'teki ağaç için düğüm adresi: html->div->tr(0)
Şekil 4'teki ağaç için düğüm adresi: html->div->div->tr(0)

V. ÇÖZÜM

A. Çözümde Kullanılan Elemanlar ve Akış



Şekil 5. Uygulama Elemanları ve Akış

Şekil 5'te görülen tüm aşamalar için uygulamalar geliştirilmiştir. Uygulamaların birbirinden bağımsız şekilde çalışabilir olmalarına özen gösterilmiştir. Bu sayede geliştirme aşaması minimum bağımlılık ile devam ettirilmiştir.

B. Görsellerin Elde Edilmesi

Görsellerin elde edilmesi için arayüzsüz (headless) Chrome tarayıcı kullanılmıştır. Puppeteer kütüphanesi² ile önceden hazırlanmış otel bağlantılarına gidilmiş; sayfaların görselleri çekilmiş ve dosya sisteminde "hotelid-checkindate-checkoutdate-uniqueidentifier.jpeg" formatında isimlendirilerek kaydedilmiştir. Bu kaydetme işlemi öncesinde veya sonrasında görseller herhangi bir işlemde geçirilmemiştir. Sadece ön tanımlı sayfa boyutu kullanılarak gereksiz büyüklükte ekran görüntüsü kaydedilmesinin önüne geçilmiştir.

²<https://pptr.dev/>

C. Talep Sınırlama Problemi

Veri taraması yapılması muhtemel olan siteler (www.booking.com, www.github.com vb.), bu durumun farkında olduklarından internet sayfasına giren kullanıcının insan mı yoksa program mı (robot) olduğunu tespit edebilmek ve robot olduğu tespit edilen hareketlere engelleme yapabilmek için 1 dakika içinde maksimum istek sayısı sınırı uygulayabilmektedir. Bu sınıra erişen IP adreslerini de belli bir süreyle engelleyebilmektedirler. Bu engele takılmadan çok sayıda otel bilgisini tarayabilmek için mevcut bağlantı adreslerini bulut ortamındaki farklı makinalar (farklı IP'ler) üzerinden işleyip sınırlara takılmaksızın site görselleri elde edilmiştir.


D. Eşzamanlı URL İşleme

Verisi taranacak otellerin sayısının artmasıyla bağlantıların (URL) eşzamanlı işlenmesi ihtiyacı ortaya çıkmıştır. Bu doğrultuda tek makinede açılacak maksimum tarayıcı sekme sayısı ve tek IP'den istek limiti gibi konular göz önünde bulundurularak bütün bağlantıların (URL) toplam işlenme süresi optimize edilmeye çalışılmıştır.

E. Nesne Bulma

Görsellerden çıkarılmaya çalışılan verilerin olduğu bölgelerin sınıf bilgileriyle birlikte tespit edilmesi ve dikdörtgen alanın belirlenmesi temel problemlerden bir tanesidir. Bu problem ile alakalı daha önce kullanılmış yaklaşımlardan Bölüm II'de detaylı bir şekilde bahsedilmiştir. Bu çalışmada bulunması hedeflenen nesneler; alternatif fiyatlar ve en ucuz fiyat gibi alanları bulunduran dikdörtgensel bölgelerdir.

1) *Derin Öğrenme Mimarisi:* Bu çalışmada kullanılan RetinaNet mimarisinin iskelet ağı, Şekil 6'da görüldüğü gibi ResNet üzerine inşa edilmiş Özellik Piramit Ağı'dır (Feature Pyramid Net). Bu ağ resmin evrimsel özellik haritasının hesaplanmasından sorumludur. Bu ağın çıktıları nesne sınıflandırma ve konumlandırma yapılmak üzere alt ağlara gönderilir. Kullanılan modelde, 36 milyona yakın parametre olup, öğrenme transferi yaklaşımı ile sinir ağının son katmanlarındaki parametreler güncellenerek eğitim yapılmıştır.



Şekil 6. Retinanet Mimarisi

2) *Eğitim, Validasyon ve Test verilerinin Belirlenmesi:* Toplam veri 28000 civarında olup, Bölüm III-C'de bahsedildiği gibi iki farklı veri seti oluşturulmuştur. Her bir veri setinde eğitim, validasyon ve test için aşağıda bahsedilen işlemler uygulanmıştır:

- Tüm verinin yüzde 10'u test için ayrılmıştır.
- Geri kalan kısım, eğitim verisi olarak kullanılmıştır.
- Veri ayrımında rastsal seçim metodu kullanılmıştır.
- Validasyon için 10 katlamalı çapraz doğrulama yaklaşımı kullanılmıştır.

Tüm validasyon ayrışmaları için, ortalama isabet değeri veri I için 0.98 veri II için 0.90 civarında çıkmıştır.

F. Veri Arttırma

Veri arttırma yöntemi, özellikle CNN tabanlı derin öğrenme algoritmalarında modelin ezberlenmesine engel olan ve daha kapsamlı model oluşmasını sağlayan bir yaklaşımdır. Literatürde genel olarak 2 değişik veri arttırma metodu bulunmaktadır [11]. Bu metodlardan biri, ÜÇA (Üretken Çekişmeli Ağ) yaklaşımı kullanılarak verinin çoğaltılması, diğeri de geleneksel dönüşüm metodları kullanılarak verinin genelleştirilmesidir. Bu çalışmada geleneksel dönüşüm metodlarından yerel deformasyonlar, yakınlaştırma ve kaydırma metodları kullanılmıştır.


G. Optik Karakter Tanıma

Optik Karakter Tanıma (OKT) kapsamında görsel üzerindeki el yazılarının veya bilgisayar yazılarındaki karakterlerin örüntü tanıma, makine öğrenmesi ve bilgisayarlı görme teknikleri kullanılarak algılanmasıdır. Bu çalışmada Tesseract OCR kütüphanesi ³ kullanılarak ilgili alanlardaki karakterlerin neler oldukları tespit edilmiştir.

VI. BAŞARIM DEĞERLENDİRMESİ

A. mAP Metriği

Literatürde mAP (mean average precision) olarak bilinen bu metrik sayesinde nesne tanımlama algoritmalarının performansı başarılı bir şekilde ölçülebilmektedir [12]. Bu çalışmada, birçok nesne bulma çalışmasında da kullanılan bu mAP metriği kullanılmıştır.



Şekil 7. mAP hesaplanışı

mAP hesaplamak için öncelikle, işaretlenen alanın tahmin edilen kategorisi ile gerçek kategorisinin örtüşmesi gerekmektedir. Bu kategoriler örtüştükten sonra kategorisi tahminlenen resmin olduğu alanın gerçek konumu ile tahmin edilen alanın konumu arasındaki kesişiminin bu alanların birleşimine oranı Şekil 7'deki gibi bulunur. Bu orana IOU (intersection over union) denmektedir. mAP ise tüm görseller için hesaplanmış olan AP değerlerinin ortalamasıdır. mAP hesaplanırken AP değerinin 0.5'ten büyük olması beklenmektedir. Aksi takdirde mAP hesaplanırken bu değer sıfır olarak kabul edilmektedir.

B. Deneysel Sonuçlar

Testler ve eğitimler Tablo II'de belirtilen her iki ortamda da gerçekleştirilmiştir.

Deney ortamı 2'de tüm görseller ile modelin bir defa eğitilmesi 40 dk. mertebelerinde iken Deney ortamı 1'de 309 saat sürmektedir. Test süreleri Deney ortamı 2'de tüm test görselleri için 4 dk. mertebelerinde iken Deney ortamı 1'de 1.7 saat sürmektedir.

³<https://github.com/tesseract-ocr/tesseract>

TABLO II. DENEY ORTAMLARI ÖZELLİKLERİ

Özellikler	Deney Ortamı 1	Deney Ortamı 2
Local/Cloud	Local	Cloud
CPU	Intel Core i7	Intel® Xeon® E5-2660
	2.2 GHz	2.2 GHz
	4 çekirdek	8 çekirdek
GPU	Yok	NVIDIA V-100 Tesla
RAM	16 GB	60 GB

Tablo III. VERİ I KÜMESİNDEKİ TESPİTLER

Sınıf	adet	mAP
Alternatif Fiyat 1	2264	0.9991
Alternatif Fiyat 2	2005	0.9995
Alternatif Fiyat 3	1438	0.9998
En Düşük Fiyat	2848	0.9993

Tablo IV. VERİ II KÜMESİNDEKİ TESPİTLER

Sınıf	adet	mAP
Alternatif Fiyat 1	2263	0.9494
Alternatif Fiyat 2	2004	0.9261
Alternatif Fiyat 3	1437	0.9990
En Düşük Fiyat	2845	0.8263


TABLO V. VERİ III KÜMESİNDEKİ TESPİTLER

Sınıf	adet	mAP
Alternatif Fiyat 1	10	0.2500
Alternatif Fiyat 2	11	0.0909
Alternatif Fiyat 3	6	0.0417
En Düşük Fiyat	10	0.0993

Tablo III ve IV'te görüldüğü üzere mevcut sınıflar için mAP değerleri yüksek çıkmıştır. Bu durumun nedeni kullanılan test görselleri kümesinin yine aynı internet sayfasından elde edilmiş, eğitim için kullanılan görsellerdeki otellerden farklı otellere ait fiyat bilgilerinin bulunduğu görsellerden oluşuyor olmasıdır. Bu görseller web sitesinden ekran görüntüsü kaydedilerek elde edildiğinden, herhangi bir gürültü, ışık değişimi, harekete bağlı bozulma gibi problemler oluşmamaktadır. Aynı zamanda bu görseller yapısal olarak eğitim için kullanılan görsellerle de büyük benzerlik göstermektedirler. Ezberleme (Overfitting) olup olmadığını ve ne kadar kapsamlı bir model elde edildiğini görebilmek için elle üretilmiş ve aşırı bozulmaların olduğu görsellerle de modelin başarısı test edilmiştir. Tablo V'te görüldüğü üzere mAP değerleri düşük çıkmıştır. Bunun 2 temel sebebi bulunmaktadır. Birincisi, model eğitilirken Veri III'te bulunanlara benzer bozunumlara sahip verilerin kullanılmamış olmasıdır. Diğer önemli sebep ise mAP hesaplama yöntemidir. mAP hesaplanırken kesişim alanının tüm alana oranının 0.5'ten büyük olması beklenmektedir. IOU değeri bu eşik değerden düşük çıktığında; IOU sıfır olarak kabul edilmektedir. Dolayısıyla, bu durum tüm görsellerin AP değeri ortalaması olan mAP değerini de düşürmektedir.

VII. TARTIŞMA

Veri kazıma performansını etkileyen en önemli faktör sayfanın tasarımsal yapısında meydana gelen değişikliklerdir. Bu çalışmanın amacı sayfa tasarımındaki değişikliklerden etkilenmeden görsel üzerinden verinin çekilebilmesidir. Bunun için hedef alanlar (alternatif fiyat, en ucuz fiyat vb.) makine öğrenmesi ile tespit edilmekte, sonrasında ilgili alanlardaki karakterler OKT yaklaşımı ile çıkarılmaktadır. Bölüm VI-B'de özellikle Tablo III'de gösterilen verilerle yapılan



Şekil 8. Veri III'de tespit edilen fiyatları

test sonuçları kabul edilebilir seviyede yüksek çıkmıştır. Bu veri kümesi oluşması muhtemel gerçekçi sayfa görüntü değişimlerini barındırmaktadır. Görselde yapısal değişikliğe neden olmayan yahut küçük değişikliklere (Fiyat bilgisinin herhangi bir yöne 0.5 cm kayması) sebebiyet veren HTML ağaç değişikliklerinde, geliştirdiğimiz sistemin başarılı bir şekilde veri çıkarabildiği de Tablo III ve IV'teki sonuçlarda gözlemlenmiştir. Tablo V'te değerler çok düşük çıkmasına rağmen, alan tespitlerindeki isabet oranı Şekil 8'da görüldüğü üzere mAP sonuçlarından çok daha iyi çıkmıştır. Bu farklılığın nedeni, detaylarından Bölüm VI-B'de bahsedilmiş olan mAP hesaplamasının, eşik değeri kullanıyor ve Veri III'de kullanılan görsellerdeki bozulmaların, eğitilen veri setindeki bozulmalardan çok daha farklı olmasıdır.

Sonuç olarak bu çalışma takip edilecek sitelerdeki verilerin, görüntü işleme yaklaşımı ile elde edilip edilemeyeceğini anlamak amacıyla yapılmıştır. İleriye dönük olarak hem takip edilen site sayısı artırılacak hem de veri artırılmasında daha farklı bozulmalar ve dönüşümler eklenecektir. Bu çoğaltılmış verilerle çok daha kapsamlı ve değişikliklere çok daha dayanıklı bir model elde edilecektir.

KAYNAKLAR

- [1] Ujwal B V S, Bharat Gaiind, Abhishek Kundu, et al. "Classification-based Adaptive Web Scraper" 2017 16th IEEE International Conference on Machine Learning and Applications
- [2] Chu, Yu-Chun, et al. "Automatic data extraction of websites using data path matching and alignment." Digital Information Processing and Communications (ICDIPC), 2015 Fifth International Conference on. IEEE, 2015.
- [3] Chang, Chia-Hui, et al. "A survey of web information extraction systems." IEEE transactions on knowledge and data engineering 18.10 (2006): 1411-1428.
- [4] Shah, Jenil, and Viral Gokani. "A Simple and Effective Optical Character Recognition System for Digits Recognition using the Pixel-Contour Features and Mathematical Parameters." (IJCSIT) International Journal of Computer Science and Information Technologies 5.5 (2014).
- [5] Lin, Tsung-Yi, et al. "Focal loss for dense object detection." IEEE transactions on pattern analysis and machine intelligence (2018).
- [6] Girshick, Ross, et al. "Rich feature hierarchies for accurate object detection and semantic segmentation." Proceedings of the IEEE conference on computer vision and pattern recognition. 2014.
- [7] Lin, Tsung-Yi, et al. "Feature Pyramid Networks for Object Detection." CVPR. Vol. 1. No. 2. 2017.
- [8] Lin, Tsung-Yi, et al. "Microsoft coco: Common objects in context." European conference on computer vision. Springer, Cham, 2014.
- [9] Redmon, Joseph, et al. "You only look once: Unified, real-time object detection." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.

- [10] Liu, Wei, et al. "Ssd: Single shot multibox detector." European conference on computer vision. Springer, Cham, 2016.
- [11] Perez, Luis, and Jason Wang. "The effectiveness of data augmentation in image classification using deep learning." arXiv preprint arXiv:1712.04621 (2017).
- [12] Everingham, Mark, et al. "The pascal visual object classes (voc) challenge." International journal of computer vision 88.2 (2010): 303-338.